DOKUMENT 02 / IMPLEMENTÁCIA

Technická správa

Architektúra dát, inferenčný algoritmus, modelové artefakty a reprodukovateľnosť GitHub vydania.

SCHÉMA	ML VSTUP	BUILD
217	111	GRCh37

STATUS DOKUMENTU Verzia 0.1.0, 14. október 2026. Verejný výskumný výstup. Výsledky nie sú klinickou validáciou ani diagnózou.

01 / ÚČEL

Rozsah systému

Pilot je samostatný statický projekt publikovaný cez GitHub Pages. Pôvodné rozhranie AlergenRisk nemení. Verejná aplikácia poskytuje lokálny výpočet, prehliadač syntetických dát, audit SNP/proxy a dokumentačný balík. Nie je potrebný server ani cloudová analytická služba.

OCHRANA VSTUPU	Genotypový súbor sa parsuje a vyhodnocuje v prehliadači. Aplikácia ho neodosiela na server.

02 / VRSTVY

Architektúra

Vrstva	Artefakt	Zodpovednosť
Register	config/celiac_model_v1.json	Lokusy, alely, váhy, HLA a populácia
Proxy audit	config/celiac_proxy_audit_v1.json	EUR r², D', mapovanie alel, zdroj
Dáta	data/synthetic/*.csv.gz	Syntetické prípady a fixné splity
Model	artifacts/models/*.npz	Normalizácia, váhy a threshold
Web export	site/assets/*.json	Prenositeľné artefakty pre prehliadač
Audit	artifacts/release-manifest.json	SHA-256, veľkosť a verzia

03 / PRAVIDLÁ

Inferenčný algoritmus

Parser prijíma bežné textové, CSV a TSV exporty s rsID a dvojpísmenovým genotypom. Každý z 50 cieľov sa vyhodnotí presne raz.

Priorita	Zdroj	Výpočet	Kvalita
1	direct	Celé číslo 0, 1 alebo 2 podľa efektovej alely	1,00
2	proxy	Očakávaná dávka z podmienených pravdepodobností	EUR r²
3	population	2 x referenčná frekvencia alebo HLA frekvencia	0,00

Transparentné skóre sa počíta ako HLA diplotypová váha plus vážený súčet aditívnych dávok. Genetické vstupy zostávajú oddelené od indikátorov kvality. Výsledok s pokrytím menším než 50 % sa označí ako nedostatočný.

04 / STRUCTURED MODEL

Modelové príznaky

DÁVKY	KVALITA	PROFIL
50	50	5

HLA PÁRY	HLA X JADRO	MISSING X JADRO
4	1	1

Spolu 111 príznakov. Päť profilových indikátorov opisuje complete, 23andme_like, myheritage_like, dnaera_like a sparse_stress. Identifikácia profilu je pomocná stresová vrstva; reálna dostupnosť markerov sa určuje z obsahu súboru.

ODDELENÉ VÝSTUPY Rozhranie zobrazuje transparentné referenčné skóre a výskumnú ML triedu osobitne. ML pravdepodobnosti sú pravdepodobnosti tried syntetického oracle, nie ochorenia.

05 / BUILD A TEST

Reprodukcia

Referenčný postup pre Python 3.11:

Krok	Príkaz
Inštalácia	python -m pip install -r requirements-lock.txt
Pipeline	python scripts/run_pipeline.py --samples 12000 --seed 20261014
Web export	python scripts/build_release_assets.py
Python testy	python -m unittest discover -s tests -v
Web testy	node --test tests/web_app.test.mjs

Referenčný dataset: 12000 riadkov, 217 stĺpcov. Manifest SHA-256: 87c607a0805b8729284a39ff73637b37be846ed3dfea09bb4b40ea89e6baeb59. Dataset SHA-256: bba1ff01636b5eed3f71ec5730d28d31940b5aed6e6b52a43eb2ac56bdd2388f.

06 / RELEASE

Prevádzkové kontroly

- GitHub Actions spúšťa Python testy, zmenšený validačný beh, export release artefaktov a JavaScript testy.
- GitHub Pages publikuje výhradne obsah priečinka site.
- Release manifest eviduje verziu, SHA-256 a veľkosť kľúčových súborov.
- Licencia musí byť pred formálnym odovzdaním potvrdená vlastníkom projektu.
- Externá klinická validácia a integrácia s inou platformou nie sú súčasťou verzie 0.1.0.