DOKUMENT 01 / VEDECKÝ RÁMEC

Výskumná štúdia

Holistický polygénny model celiakálnej predispozície a jeho syntetická algoritmická validácia.

PRÍPADY	MARKERY	MODELY
12 000	50	3

STATUS DOKUMENTU Verzia 0.1.0, 14. október 2026. Verejný výskumný výstup. Výsledky nie sú klinickou validáciou ani diagnózou.

01 / KONTEXT

Abstrakt

Cieľom pilotu je overiť, či možno genetickú logiku celiakálneho panelu previesť do explicitného, reprodukovateľného a strojovo čitateľného procesu. Model neredukuje výsledok na prítomnosť jednej rizikovej mutácie. Kombinuje 42 aditívnych lokusov, 8 HLA tag markerov, diplotypový HLA člen a kvalitu každého genetického dôkazu.

Na 12 000 syntetických prípadoch sa porovnali tri modely. Najlepší structured model dosiahol macro F1 0,880 a ROC-AUC 0,980 pre rozlíšenie vysoko predisponovanej triedy. Tieto hodnoty merajú vernosť voči syntetickému oracle, nie klinickú predikciu celiakie.

HLAVNÝ ZÁVER	Pilot spĺňa reprodukovateľnú dátovú a validačnú vrstvu grantového zámeru pre celiakiu. Klinické tvrdenia zostávajú podmienené externou fenotypovanou kohortou.

02 / ZDROJE

Vedecké východiská

Jadro aditívneho skóre vychádza z publikovaného GRS42 a záznamu PGS000316. Sharp a kol. opísali 42-SNP genetické rizikové skóre celiakie a jeho výkon v európskych súboroch. HLA komponent využíva tagovacie princípy opísané Monsuurom a kol. Referenčné hranice sú odvodené z modelovanej EUR/CEU distribúcie.

Vrstva	Rozsah	Úloha
Aditívne jadro	42 lokusov	Súčet dávka efektovej alely x logaritmická váha
HLA	8 tag SNP	Odhad DQ2.5, DQ8, DQ2.2 a DQ7.5
Neistota	50 indikátorov	Rozlíšenie direct, proxy a population
Interakcie	6 príznakov	HLA páry, HLA x jadro, chýbanie x jadro

03 / EXPERIMENT

Metódy

Generátor vytvoril genotypové dávky podľa EUR frekvencií a HLA diplotypov. Každá syntetická vzorka prešla jedným z piatich stresových profilov pokrytia. Oracle skóre a trieda boli určené nezávisle od trénovania. Dáta boli stratifikovane rozdelené na train, validation a test. Prah vysokej triedy sa vybral výlučne na validačnom splite s cieľom recall aspoň 0,95.

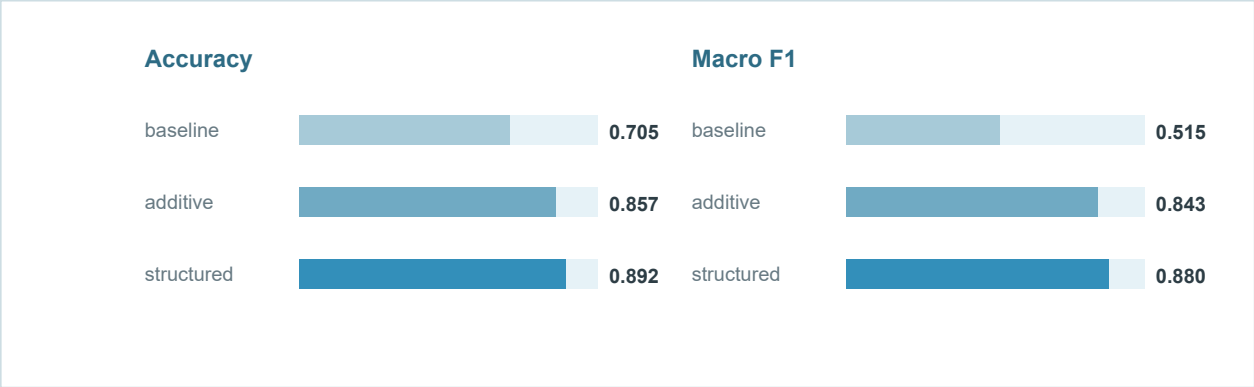
TRAIN	VALIDATION	TEST
7 198	2 401	2 401

Rozhodovacie hranice referenčného modelu sú q20 = 1,20 a q80 = 4,06. Pozorované skóre sa zaokrúhľuje na mriežku 0,02 bodu. Ak chýba cieľový marker, poradie spracovania je direct, auditovaná proxy, potom neisté populačné očakávanie.

04 / KOMPARATÍVNA ANALÝZA

Výsledky

Model	Príznaky	Accuracy	Macro F1	High recall	High precision	FNR	ROC-AUC
baseline	5	0.705	0.515	1.000	0.200	0.000	0.882
additive	105	0.857	0.843	0.948	0.576	0.052	0.963
structured	111	0.892	0.880	0.950	0.710	0.050	0.980



Baseline dosiahol recall 1,000 iba pri prahu, ktorý označil všetkých testovaných ako pozitívnych, a preto má precision 0,200 a špecificitu 0. Structured model zachoval recall približne 0,95 a zvýšil precision na 0,71.

INTERPRETÁCIA Zlepšenie structured modelu ukazuje prínos agregovaného panelu a explicitnej štruktúry. Nejde o dôkaz biologickej epistázy ani o klinickú účinnosť.

05 / HRANICE

Diskusia a obmedzenia

- Syntetické triedy kopírujú definovaný genetický oracle; nejde o diagnózu.
- Referenčné frekvencie a LD sú viazané na EUR/CEU a nemožno ich bez validácie preniesť na iné populácie.
- Štyri research-extension lokusy nie sú súčasťou pôvodnej klinickej validácie GRS42.
- Simulované čipové profily sú stresové scenáre, nie meranie konkrétnej komerčnej revízie.
- Pred klinickým použitím je potrebná externá kohorta, kalibrácia absolútneho rizika a odborné posúdenie.

06 / PRIMÁRNE ZDROJE

Referencie

1. PGS Catalog. PGS000316 - Coeliac disease genetic risk score. https://www.pgscatalog.org/score/PGS000316/

2. Sharp SA et al. A single nucleotide polymorphism genetic risk score to aid diagnosis of coeliac disease. Aliment Pharmacol Ther. 2020. PMID 32790217.

3. Monsuur AJ et al. Effective detection of human leukocyte antigen risk alleles in celiac disease using tag SNPs. PLoS One. 2008. PMID 18509540.

4. 1000 Genomes Project Phase 3. GRCh37 phased reference data.
https://www.internationalgenome.org/data-portal/data-collection/phase3/

07 / VÝSTUP

Dostupnosť a audit

Modelový register, syntetický dataset, zdrojový kód, metriky a kontrolné súčty sú publikované v jednom verzovanom GitHub repozitári. Verejná aplikácia umožňuje stiahnuť dátový slovník, syntetickú demo vzorku a metodické dokumenty.

Artefakt	Úloha
celiac_model_v1.json	Definícia genetickej logiky
celiac_pilot_v1.csv.gz	Anotovaný syntetický tréningový materiál
evaluation.json	Úplné validačné metriky
checksums.sha256	Kontrola integrity release balíka

TRVALÁ HRANICA Bez nezávislej klinickej kohorty sa výstup smie označovať iba ako výskumná genetická predispozícia a algorithmic fidelity.