DOKUMENT 05 / VIACZNAKOVA METODIKA

AlergenRisk Research Pilot

Jednotna metodika, syntetické datasety a komparativna validacia pre sedem genetickych modulov od vajca po histamin/DAO.

ZNAKY	PRIPADY	PANEL-LOKUSY
7	48 000	71

STATUS DOKUMENTU Verzia 0.2.0, 14. oktober 2026. Verejny vyskumy vystup. Metriky nie su klinickou validaciou ani diagnozou.

01 / SUHRN

Vyskumy ciel a rozsah

Projekt aplikuje jednu reprodukovatelnu auditnu architekturu na vajce, arasidy, kravske mlieko, spolocnu potravinovu predispoziciu, laktozu, celiakiu a histamin/DAO. Nezjednocuje vsak biologiu nasilu. Kazdy znak si zachovava vlastny typ modelu, silu dokazov, politiku proxy a pravidlo pre chybajuci marker.

Celiakia pouziva rozsiahle vazene jadro a HLA diplotyp. Vajce, arasidy, mlieko a spolocny panel su experimentálne multilokusove modely. Laktoza ostava jednovariantovym genotypovym pravidlom. Histamin/DAO ostava kandidatnym panelom aktivity enzymu.

HLAVNY PRINCIP Rovnaky proces neznamena rovnake vedecke tvrdenie. Register, data, validacia a audit su jednotne; interpretacia zostava primerana dokazom.

02 / SEDEM MODULOV

Modelova mapa

Znak	Ciele	Model	Chybajuci ciel	Hlavna hranica
Vajce	4	multilokusovy aditivny	population iba pre ML	bez klinickej kalibracie
Arasidy	5	HLA + kandidati	population iba pre ML	HLA markery mozu byt jeden LD signal
Kravske mlieko	5	3 povinne proxy + 2 direct	population iba pre ML	mala kandidatna studia
Spolocny panel	3	vseobecna potravinova alergia	population iba pre ML	nerozlisuje potraviny
Laktoza	1	genotypove pravidlo	bez imputacie	populacna specificita
Celiakia	50	GRS + HLA diplotyp	direct/proxy/population	relativna predispozicia
Histamin / DAO	3	AOC1 alelovy sucet	bez imputacie	DAO aktivita nie diagnoza

03 / REGISTER A POVOD

Forenzna datova logika

Kazdy zaznam uchovava simulovanu pravu davku, numericky vstup modelu, povod direct/proxy/population/missing, kvalitu, cele geneticke skore, vazene skore, triedu a fixny split. Populacne ocakavanie je numericky ML priznak s kvalitou 0, nie individualny genotyp.

Povod	Numericky vstup	Cele skore	Kvalita	Interpretacia
direct	davka 0/1/2	0/1/2	1,00	priamo zisteny ciel
proxy	najpravdepodobnejsia davka	0/1/2	EUR r2	odhad ciela, neistota osobitne
population	2 x frekvencia	0	0,00	iba ML stabilizacia
missing	neutralny numericky vstup	0	0,00	ziadna individualna informacia

MLIEKO Proxy rs115288876, rs63582760/rs10588133 a rs17388568 prispievaju do genetickeho skore vzdy celym cislom. Pravdepodobnost proxy odhadu zostava oddelena.

04 / DATA A SPLITY

Synteticky experiment

CELIAKIA	KAZDY DALSÍ	SPOLU
12 000	6 000	48 000

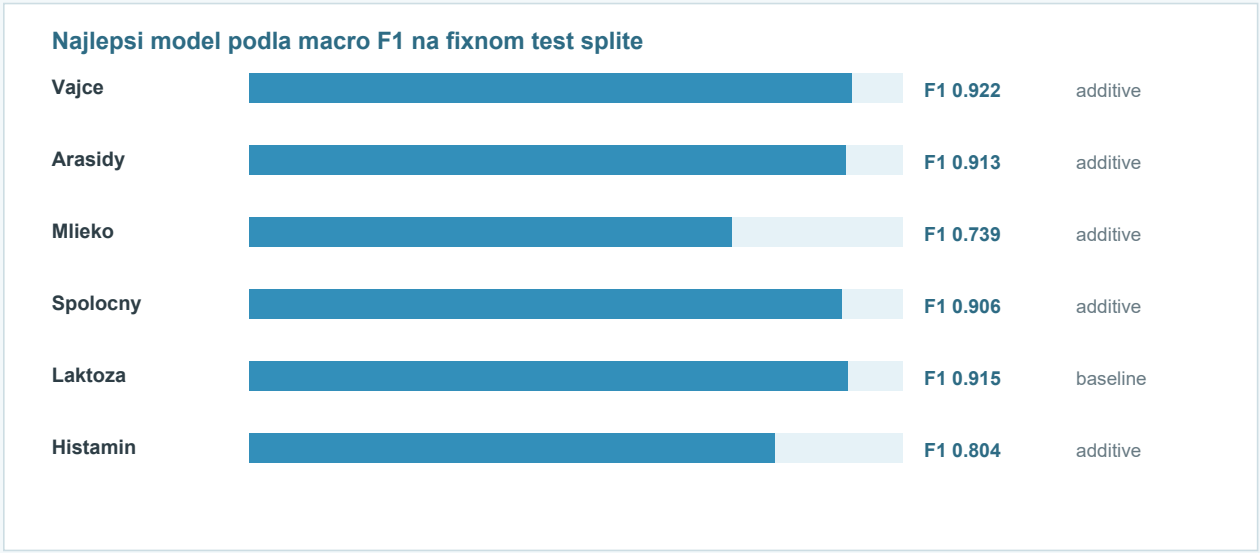
Kazdy dataset ma stratifikovane rozdelenie 60 % train, 20 % validation a 20 % test. Pat profilov pokrytia vytvara technicke stresove scenare. Ich nazvy pripominaju bezne exporty, ale nie su meranim kvality konkretnej znacky alebo revizie cipu.

- baseline: veduci marker, jeho kvalita a pokrytie
- additive: vsetky davky, kvalita a profil
- structured: additive vrstva plus parove statisticke interakcie a chybajucnost
- prah najvyssej triedy: zvoleny iba na validation splite
- test split: pouzity az po zafixovani prahu

05 / TEST VYSLEDKY

Komparativna validacia

Znak	Najlepsi	Macro F1	High recall	High precision	High FNR
Vajce	additive	0.922	0.952	0.656	0.048
Arasidy	additive	0.913	0.936	0.810	0.064
Mlieko	additive	0.739	0.975	0.190	0.025
Spolocny	additive	0.906	0.931	0.842	0.069
Laktoza	baseline	0.915	1.000	0.585	0.000
Histamin	additive	0.804	0.842	0.593	0.158



Structured interakcie neboli automaticky najlepsie. Pri piatich zo siestich novych modulov bol podla macro F1 lepsi aditivny alebo pravidlovy pristup. Tento negativny vysledok sa zachovava, pretoze projekt nesmie prisudzovat interakciam hodnotu bez dokazov.

FALSE NEGATIVES

Mliecny high-sensitivity prah dosahuje vysoky recall za cenu nizkej precision. Histaminovy panel nedosiahol ciel recall 0,95 a nesmie sa prezentovat ako vysokocitlivy skrining.

06 / CO VYSLEDKY ZNAMENAJU

Interpretacia metrik

- Confusion matrix, precision, recall, F1, ROC-AUC, PR-AUC a Brier score hodnotia zhodu so syntetickym oracle.
- Vysledky nie su klinickou citlivostou, specificitou ani diagnostickou AUC.
- Vyssie macro F1 nepotvrdzuje biologicku kauzalitu lokusov.
- Proxy r2 je technicka kvalita odhadu, nie klinicka spolahlivost interpretacie.
- Absolutne riziko vyzaduje fenotypovanu kohortu a kalibracny model.

07 / PROVENANCE

Vedecke zdroje a sila dokazov

Panel	Primarny zdroj	Pouzitie
Vajce / spolocny	Marenholz et al. 2017, 10.1038/s41467-017-01220-0	GWAS lokusy a efekty
Arasidy	Hong et al. 2015, 10.1038/ncomms7304	replikovane HLA markery
Arasidy	Asai et al. 2018, 10.1016/j.jaci.2017.09.015	sugestivne kandidatne lokusy
Mlieko	Henneman et al. 2016, 10.1186/s13601-016-0096-9	kandidatne asociacie
Laktoza	Enattah et al. 2002, PMID 11788828	rs4988235 pravidlo
Histamin / DAO	Maintz et al. 2011, 10.1111/j.1398-9995.2011.02548.x	AOC1 a aktivita DAO
Celiakia	PGS000316; Sharp 2020; Monsuur 2008	GRS a HLA logika

08 / GRANTOVY VYSTUP

Akceptacny stav

Poziadavka	Doklad v projekte	Stav
Agregovane geneticke skore	sedem explicitnych oracle modelov	splnene metodicky
Interakcie	structured comparator; HLA diplotyp pri celiakii	otestovane
Forenzna presnost	JSON registre, provenance, checksumy	splnene
Syntheticke datasety	48 000 pripadov a fixne splity	splnene
Metriky	CM, precision, recall, F1, AUC, FNR, Brier	splnene
Komparativna studia	baseline/additive/structured	splnene
Klinicka validacia	nezavisla fenotypovana kohorta	otvorene
Externy system	bod 6 bol zamerne vynechany	mimo rozsahu

09 / HRANICE ODOVZDANIA

Dalsie kroky

- Odborna revizia kandidatnych panelov mlieko, arasidy a histamin/DAO.
- Nezavisla fenotypovana kohorta pre kazdy klinicky zamyslany vystup.
- Kalibracia absolutneho rizika, subgroup analyzy a prospektivny protokol.
- Oddelenie technickeho pokrytia cipu od klinickej diskriminacie.
- Volba licencie vlastnikom pred nemennym GitHub release.

10 / REPRODUKOVATELNOST

Odovzdany balík

Verzia 0.2.0 je publikovatelny GitHub balík bez serverovej zavislosti. Kazdy vystup ma jasny zdroj, verziu a kontrolny sucet. Staticka aplikacia vykona analyzu genotypoveho suboru lokalne v prehliadaci.

Artefakt	Obsah	Auditna funkcia
trait_models_v1.json	6 registrov mimo celiakie	alely, vahy, proxy, zdroje
celiac_model_v1.json	50-markerovy celiakalny register	GRS a HLA logika
*_pilot_v1.csv.gz	7 syntetickych datasetov	train/validation/test material
evaluation.json	kompletne metriky modelov	CM, F1, AUC, FNR, Brier
site/assets/*.json	browserove modely a audity	lokalna reprodukcia vysledku
checksums.sha256	kontrolne sucty	integrita release balika

11 / STOP PODMIENKY

Kontrolny zoznam pred klinickou etapou

- Schvalit protokol a primarny klinicky endpoint pre kazdy znak.
- Ziskat nezavisle fenotypovane a populacne primerane data.
- Zafixovat model pred otvorenim externej testovacej kohorty.
- Reportovat kalibraciu, subgroup vykon a rozhodovacie krivky.
- Zachovat oddelenie vyskumneho skore od diagnozy a liecebneho rozhodnutia.

ZAVER

Projekt ma teraz spolocnu reprodukovatelnu vyskumy vrstvu pre vsetky znaky. Akceptovatelnost klinickych tvrdeni vsak zostava zavisla od realnych fenotypovanych dat.